

## 12.2 共分散行列と同時確率

線形代数は $M$ 個の異なる実験を一度に行うときに登場する。 $N$  人について年齢と身長と体重を $M=3$  回測るとする。各実験はそれぞれについて平均値を計算できる。そこで、 $M$  個の平均値を含むベクトル $m = (m_1, m_2, m_3)$ を考える。これらは年齢と身長と体重の標本平均かもしれないし、既知の確率に基づく年齢、身長、体重の期待値かもしれない。

行列は分散の計算に用いる。各実験について、標本分散 $S_i^2$ 、または平均からの距離の2乗に基づく期待値 $\sigma_i^2 = E[(x_i - m_i)^2]$ が計算できる。これらの $M$ 個の数値  $\sigma_1^2, \dots, \sigma_m^2$  は「分散-共分散行列」の主対角線上に位置している。ここまでで、 $M$ 個の並列実験の間には何の関係もない。これらは異なる確率変数を測定しているが、実験は必ずしも独立ではない。

子供の年齢( $a$ )と身長( $h$ )と体重( $w$ )を測定すると、その結果には強い相関がある。一般に年長の子どもは身長が高く、体重も重い。平均値 $m_a, m_h$ は既知であるとする。そして、 $\sigma_a^2, \sigma_h^2, \sigma_w^2$ は年齢、身長、体重の分散である。 $\sigma_{ah}$ は、年齢と身長に関連を測定する共分散である。

**Covariance**     $\sigma_{ah} = E[(\text{age} - \text{mean age})(\text{height} - \text{mean height})].$

 (1)

この定義はよく見ておく必要がある。 $\sigma_{ah}$  を計算するためには、各年齢の確率と各身長の確率を知るだけでは不十分である。各組（年齢と身長）の結合確率を知らなければならない。これは、年齢と身長が結びついているからである。

$p_{ah}$ = 年齢が  $a$  で身長が  $h$  の無作為な子供の確率

$p_{ij}$ =実験 1 の結果が $x_i$ で、実験 2 の結果が $y_j$ の確率

実験 1（年齢）の平均が $m_1$ であったとする。実験 2（身長）の平均は  $m_2$  である。実験 1 と実験 2 の間の式(1)の共分散は、年齢 $x_i$ と身長 $y_j$ のすべての組に注目する。そのペアの同時確率 $p_{ij}$ を掛ける。

**Expected value of**  
 $(x - m_1)(y - m_2)$

**Covariance**     $\sigma_{12} = \sum_{\text{all } i, j} p_{ij}(x_i - m_1)(y_j - m_2)$

 (2)

この「同時確率 $p_{ij}$ 」を計算するために、まず、例を2つ見てみる。

例 1. 2 枚のコインを別々に投げる。1 が表で 0 が裏の場合、結果は(1,1)か(1,0)か(0,1)か(0,0)のどれかである。

この 4 つの結果は、すべて確率 $(1/2)^2 = 1/4$ となる。

独立した実験では、確率を掛け合わせる。

$p_{ij} = (i, j)$ の確率  $= (i$ の確率) $\times (j$ の確率)

例 2 コインを同じ向きで接着する。結果は(1,1)と(0,0)だけである。これらの確率は  $1/2$  と  $1/2$  である。確率 $p_{10}$ と $p_{01}$ は 0 である。(1,0)と(0,1)は、コインが接着されているので起こらない：表が出るか裏が出るかのどちらかしかない。

## Joint probability matrices for Examples 1 and 2

$$P = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{4} \end{bmatrix} \quad \text{and} \quad P = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{2} \end{bmatrix}.$$

$P$  をうまく行列表記にするために、もう少し詳しく説明しよう。この行列は、 $(x_1, y_1) = (\text{head}, \text{heads})$  と  $(x_1, y_2) = (\text{heads}, \text{tails})$  から始まる各対  $(x_i, y_j)$  の確率  $p_{ij}$  を示している。行の和  $p_1, p_2$ 、列の和  $P_1, P_2$ 、そして総和=1 であることに注目しよう。

$$\text{Probability matrix } P = \begin{bmatrix} p_{11} & p_{12} \\ p_{21} & p_{22} \end{bmatrix} \quad \begin{matrix} p_{11} + p_{12} = p_1 \\ p_{21} + p_{22} = p_2 \end{matrix} \quad \begin{matrix} \text{(first} \\ \text{coin)} \end{matrix}$$

(second coin) column sums  $P_1 \quad P_2$       4 entries add to 1

それらの和  $p_1, p_2, P_1, P_2$  が同時確率行列  $P$  の周辺分布である。

$p_1 = p_{11} + p_{12}$  = コイン 1 で表が出る確率 (コイン 2 は表か裏が出る)

$P_1 = p_{11} + p_{21}$  = コイン 2 で表が出る確率 (コイン 1 は表か裏が出る)

例 1 は、独立した確率変数である。すべての確率  $p_{ij}$  は  $p_i \times p_j$  に等しい (この例では  $1/2 \times 1/2$  で  $p_{ij} = 1/4$  となる)。この場合、共分散  $\sigma_{12}$  はゼロとなる。1 枚目のコインの表か裏かは、2 枚目のコインの結果とは関係ない。

**Zero covariance  $\sigma_{12}$   
for independent trials**       $V = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix} = \text{diagonal covariance matrix } V.$

独立した実験では、式 2) において、すべての  $p_{ij}$  が  $p_i \times p_j$  に等しいので、 $\sigma_{12} = 0$  となる。

$$\sigma_{12} = \sum_i \sum_j (p_i)(p_j)(x_i - m_1)(y_j - m_2) = \left[ \sum_i (p_i)(x_i - m_1) \right] \left[ \sum_j (p_j)(y_j - m_2) \right] = [0][0].$$

$$\sigma_{12} = [p_1(x_1 - m_1) + p_2(x_2 - m_1)][P_1(y_1 - m_2) + P_2(y_2 - m_2)] =$$

$$\left[ \frac{1}{2} \cdot \left(1 - \frac{1}{2}\right) + \frac{1}{2} \cdot \left(0 - \frac{1}{2}\right) \right] \left[ \frac{1}{2} \cdot \left(1 - \frac{1}{2}\right) + \frac{1}{2} \cdot \left(0 - \frac{1}{2}\right) \right] = \left[ \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \left(-\frac{1}{2}\right) \right] \left[ \frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \left(-\frac{1}{2}\right) \right] = 0 \cdot 0$$

$$\sigma_{11} = [p_1(x_1 - m_1) + p_2(x_2 - m_1)][p_1(y_1 - m_2) + p_2(y_2 - m_1)]$$

$$= p_1(x_1 - m_1)(P_1|p_1)(y_1 - m_2) + p_2(x_2 - m_1)(P_1|p_2)(y_1 - m_2) + p_1(x_1 - m_1)(P_2|p_1)(y_2 - m_2) + p_2(x_2 - m_1)(P_2|p_2)(y_2 - m_2)$$

$$= p_1(x_1 - m_1)1(y_1 - m_2) + p_2(x_2 - m_1)0(y_1 - m_2) + p_1(x_1 - m_1)0(y_2 - m_2) + p_2(x_2 - m_1)1(y_2 - m_2)$$

$$= \left[ \frac{1}{2} \cdot \left(1 - \frac{1}{2}\right)^2 + \frac{1}{2} \cdot \left(0 - \frac{1}{2}\right)^2 \right] = \left[ \frac{1}{2} \cdot \frac{1}{4} + \frac{1}{2} \cdot \frac{1}{4} \right] = 1/4$$

例 3 接着されたコインは、完全な相関関係を示している。一方が表ならもう一方も表である。共分散  $\sigma_{12}$  は 0 から  $\sigma_1 \times \sigma_2$  倍まで動く。これは  $\sigma_{12}$  の取りうる最大の値である。ここでは、 $(1/2)(1/2) = \sigma_{12} = (1/4)$  であることが、別の計算で確認された。

$$\text{Means} = \frac{1}{2} \quad \sigma_{12} = \frac{1}{2} \left(1 - \frac{1}{2}\right) \left(1 - \frac{1}{2}\right) + 0 + 0 + \frac{1}{2} \left(0 - \frac{1}{2}\right) \left(0 - \frac{1}{2}\right) = \frac{1}{4}$$

$$\sigma_{12} = p_1(x_1 - m_1)(P_1|p_1)(y_1 - m_2) + p_2(x_2 - m_1)(P_1|p_2)(y_1 - m_2) + p_1(x_1 - m_1)(P_2|p_1)(y_2 - m_2) + p_2(x_2 - m_1)(P_2|p_2)(y_2 - m_2)$$

$$= p_1(x_1 - m_1)(P_1|p_1)(y_1 - m_2) + p_2(x_2 - m_1)0(y_1 - m_2) + p_1(x_1 - m_1)0(y_2 - m_2) + p_2(x_2 - m_1)(P_2|p_2)(y_2 - m_2)$$

$$= p_1(x_1 - m_1)(P_1|p_1)(y_1 - m_2) + 0 + 0 + p_2(x_2 - m_1)(P_2|p_2)(y_2 - m_2) = \left[ \frac{1}{2} \cdot \frac{1}{2} + 0 + 0 + \frac{1}{2} \cdot \left(-\frac{1}{2}\right)^2 \right] = \frac{1}{4}$$

コイン 1 の表と裏は、接着したコイン 2 の表と裏の完全な情報を提供します。

**Glued coins give largest possible covariances**  
**Singular covariance matrix: determinant = 0**

$$V_{\text{glue}} = \begin{bmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \\ \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix}$$

常に  $\sigma_1^2 \sigma_2^2 \geq (\sigma_{12})^2$ 。したがって、 $\sigma_{12}$  は  $-\sigma_1 \sigma_2$  と  $\sigma_1 \sigma_2$  の間にある。行列  $V$  は正定値（この特異なコインの糊付けの場合、 $V$  は正半定値）である。これらは、 $M$  個の実験に対する  $M \times M$  個の共分散行列  $V$  すべてに関する重要な事実である。

$N$  回の実験から得られた標本共分散行列  $S$  は確実に半正定値であることに注意してください。すべての新しい標本  $X = (\text{age, height, weight})$  は標本平均  $\bar{X}$  (ベクトル) に寄与しています。各ランク 1 項  $(X_i - \bar{X})(X_i - \bar{X})^T$  は正の半正定値であり、我々はただ行列  $S$  に到達するために追加します。

$S$  には確率はなく、実際の結果のみです。

$$\bar{X} = \frac{X_1 + \cdots + X_N}{N} \quad S = \frac{(X_1 - \bar{X})(X_1 - \bar{X})^T + \cdots + (X_N - \bar{X})(X_N - \bar{X})^T}{N - 1} \quad (3)$$